

Trabalho de Algoritmos Genéticos

Parte 1

Fábio Beranizo Fontes Lopes
Escola de Artes, Ciências e Humanidades (EACH)
Universidade de São Paulo (USP)
Email: f.lopes@usp.br

I. INTRODUÇÃO

Este relatório apresenta a discussão da parte 1 do trabalho de algoritmos genéticos (GA) para a disciplina de Inteligência Computacional. Foi avaliada a utilização de GA para otimização de um conjunto de funções. O foco se manteve em analisar o comportamento do algoritmo mediante a utilização de diferentes técnicas, operadores e parametrizações.

O trabalho foi desenvolvido utilizando a linguagem de programação Python, especificamente sua distribuição Anaconda.

II. OTIMIZAÇÃO DE FUNÇÕES

O problema da otimização de funções consiste em maximizar ou minimizar uma função matemática através da escolha de valores para as variáveis, respeitando-se o domínio da função. Para o trabalho desenvolvido foram selecionadas 4 funções para análise:

$$f(x) = 20 + \sum_{i=1}^2 x_i^2 - 10 \cos(2\pi x_i)$$

intervalo para otimização: [-5, 5]

$$f(x) = \sum_{i=1}^{30} x_i^2$$

intervalo para otimização: [-100, 100]

$$f(x) = \sum_{i=1}^{30} |x_i + 0.5|^2$$

intervalo para otimização: [-100, 100]

$$f(x) = \sum_{i=1}^{30} -x_i \sin(\sqrt{|x_i|})$$

intervalo para otimização: [-500, 500]

III. CROMOSSOMO

Para a representação de uma solução do problema de otimização de funções foi necessário utilizar uma estrutura que armazenasse o valor das variáveis da solução. A escolha natural foi adotar vetores como estrutura de dados. Essa decisão facilitou a implementação dos operadores de crossover e de mutação, além de tornar simples o cálculo das funções fitness. Cada variável da solução podia assumir um valor real dentro de um domínio. Para dispor as variáveis dentro do vetor foram realizadas duas abordagens, cromossomo de valores reais e cromossomo de valores binários.

A. Cromossomo Real

No cromossomo real cada elemento do vetor assume um valor *float* que representa o valor da variável. O genótipo do indivíduo é do tipo:

$$[float_{var_1}, float_{var_2}, \dots, float_{var_n}]$$

B. Cromossomo Binário

No cromossomo binário cada elemento do vetor representa um bit de uma das variáveis da solução. Cada variável ocupa 32 bits contínuos, ou seja, 32 posições do vetor de um indivíduo. O genótipo do indivíduo é do tipo:

$$[bit1_{var_1}, bit2_{var_1}, \dots, bit32_{var_n}]$$

Na seção de discussão dos resultados serão avaliadas as vantagens e desvantagens de cada abordagem de cromossomo.

IV. SELEÇÃO DE INDIVÍDUOS

Foi analisado somente um operador de seleção de indivíduos neste trabalho. O método da roleta foi escolhido por ser de fácil implementação e por apresentar bons resultados segundo a literatura. No entanto, durante o desenvolvimento foi possível perceber que este operador aumenta o tempo de execução do algoritmo para grandes populações, uma vez que todos os indivíduos participam do sorteio.

A. Método da Roleta

O método da roleta leva em consideração o fitness de um indivíduo em relação ao fitness total da população. Nesse processo cada indivíduo possui uma probabilidade de ser selecionado (uma fatia da roleta) proporcional ao seu fitness. Embora não garanta que as melhores soluções sobrevivam, este método dá boas probabilidades às soluções

V. OPERADORES GENÉTICOS

Os indivíduos selecionados passam por um dos 3 tipos principais de operadores genéticos: reprodução, crossover e mutação.

A. Crossover

O operador crossover permite a criação de novos indivíduos a partir de organismos pais. Os descendentes possuem genótipo de ambos pais, embora geralmente sejam diferentes. O crossover é uma forma de ampliar o espaço de busca por soluções, porém mantendo-se material genético de boa qualidade de gerações anteriores.

1) *Crossover de um ponto*: O crossover de um ponto seleciona aleatoriamente um ponto de crossover nos cromossomos pais e os recombina gerando dois filhos. Este operador favorece a herança de trechos contínuos de cromossomo, o que pode ser bom quando estes trechos guardam algum significado para o fitness.

2) *Crossover uniforme*: O crossover uniforme define cada gene de um novo indivíduo copiando-se o valor de um de seus pais com uma dada probabilidade. Essa abordagem, ao contrário do crossover de um ponto, quebra trechos contínuos de cromossomo e podendo levar a uma maior diversidade do espaço de busca.

B. Mutação

TODO

1) *Mutação simples*: TODO

2) *Mutação por permutação*: TODO

VI. ELITISMO

TODO

VII. CRITÉRIO DE PARADA

TODO

VIII. GRID SEARCH

O resultado da execução do algoritmo genético está ligado diretamente aos parâmetros utilizados. Tais parâmetros podem ser selecionados eficientemente através de uma busca em parametrizações geradas a partir de um *grid*. Este processo é denominado *Grid Search*. Para o algoritmo genético desenvolvido, os parâmetros otimizados foram: tamanho da população de indivíduos e probabilidades dos operadores de reprodução, crossover e mutação.

Inserir heatmap da parametrização adicionar explicação para as tomadas de decisão sobre a parametrização descrição do processo de parametrização e observação de resultados para cada uma das funções a serem otimizadas análise dos resultados de maneira comparativa, considerando cada uma das funções otimizadas

IX. CONCLUSION

The conclusion goes here.

ACKNOWLEDGMENT

The authors would like to thank...

REFERENCES

- [1] H. Kopka and P. W. Daly, *A Guide to L^AT_EX*, 3rd ed. Harlow, England: Addison-Wesley, 1999.